Uvodni primjeri za upoznavanje sa novim funkcionalnostima i bibliotekama

Pandas

```
1 import pandas as pd # ucitaj Pandas
2 import numpy as np # ucitaj NumPy
3 data = pd.read_csv('dataset.csv') # ucitaj podatke
4 data
5
```

1 data.head() #uzimamo prvih 5 elemenata po defaultu

1 data.tail(2) #uzimamo zadnja dva reda

1 data_transponovano = data.T

2 data_transponovano #transponovanje podataka

1 data["Indeks"] #odabir jedne kolone

- 0 94-ST
- 1 77-ST
- 2 69-ST
- 3 79-ST
- 4 89-ST
- 5 78-ST

```
6
      93-ST
7
      68-ST
8
      83-ST
9
      92-ST
10
      65-ST
11
      70-ST
12
      90-ST
13
      97-ST
14
      84-ST
15
      98-ST
16
      91-ST
17
      87-ST
18
      76-ST
19
      96-ST
20
      66-ST
21
      62-ST
22
      74-ST
23
      86-ST
24
      73-ST
25
      80-ST
26
      63-ST
27
      72-ST
28
      95-ST
29
      85-ST
30
      99-ST
31
      41-ST
32
      17-ST
33
      82-ST
34
      15-ST
35
      64-ST
36
      44-ST
37
      71-ST
38
      54-ST
39
      60-ST
40
      48-ST
41
      61-ST
42
      1-ST
43
      88-ST
44
      75-ST
45
      67-ST
46
      81-ST
```

Name: Indeks, dtype: object

1 data[3:8] #uzimanje podsekvence redova

```
1 # nadji indeks studenta u 5. redu
2 data.loc[5, 'Indeks']
1 # svi studenti koji imaju ukupno preko 43 boda
2 data.loc[data['UKUPNO'] > 43]
1 # izlistaj indeks i prisustvo za trećeg,četvrtog i petog studenta
2 data.loc[2:4, ['Indeks', 'Prisustvo']]
1 df = pd.DataFrame(np.arange(25).reshape(5,5),
2 index=[5,4,3,2,1],
3 columns=['x', 'y', 'z', 'v', 'i'])
5 df
```

```
1 # loc radi sa kljucem (index) reda,
2 # i sa nazivima kolona
3 df.loc[1, 'x'] #uzimamo element sto se nalazi u redu sa id 1 i koloni x
   20
1 # iloc radi isključivo sa stvarnim (integer) indeksima
2 # (kao standardne matrice)
3 df.iloc[1, 0] #iloc posmatra dataframe objekat kao stvarnu matricu, uzimamo element na inc
   5
1 data.replace('/', np.nan, inplace=True)
2 data.head() # svaka pojava / zamijenjena sa NaN
1 data.head()
1 data.drop([2, 3, 4], inplace=True) # izbaci redove na indeksima 2, 3, i 4
2 data.head()
```

```
1 # izbaci kolonu ispit2
2 data.drop(columns=['Ispit2'], inplace=True)
3 data.head()
```

1 data

Primjeri koristenja Scikit-Learn (sklearn) biblioteke

```
1 data = pd.read_csv('dataset.csv') # ucitaj podatke
```

⁾ data menlace('/' nn nan innlace-True)

∠ uaca. reprace(/ , np.nan, inprace-n ue)

3 data

4

```
1 from sklearn.impute import SimpleImputer
2 si = SimpleImputer(strategy='mean')
3 print('Prije zamjene: ')
4 print(data.loc[:5, 'Ispit2'])
5 data.loc[:, 'Ispit2'] = si.fit_transform(data.loc[:, 'Ispit2'].values.reshape(-1,1))
6 print('Nakon zamjene: ')
7 print(data.loc[:5, 'Ispit2'])
   Prije zamjene:
         7.5
   1
         NaN
   2
         NaN
   3
         4.8
        12.5
        NaN
   Name: Ispit2, dtype: object
   Nakon zamjene:
         7.500000
   0
   1
         9.323529
```

```
2
        9.323529
    3
         4.800000
        12.500000
         9.323529
    Name: Ispit2, dtype: float64
1 from sklearn.preprocessing import scale
2 data['Ispit2'] = scale(data['Ispit2']) # Z score
3 data.loc[:5, 'Ispit2']
       -7.156096e-01
    1 6.970976e-16
       6.970976e-16
    3 -1.775173e+00
        1.246546e+00
    5 6.970976e-16
    Name: Ispit2, dtype: float64
1 from sklearn.preprocessing import MinMaxScaler
2 mm = MinMaxScaler()
3 data['Ispit2'] = mm.fit_transform(data['Ispit2'].values.reshape(-1,1))
4 data.loc[:5, 'Ispit2']
        0.379747
    0
    1
      0.495160
       0.495160
    3 0.208861
       0.696203
       0.495160
    Name: Ispit2, dtype: float64
1 import numpy as np
2 from sklearn.model_selection import train_test_split
3
4 \text{ X}, \text{ Y} = \text{np.arange}(10).\text{reshape}((5, 2)), \text{ range}(5)
6 X train, X test, Y train, Y test = train test split(X, Y,
7 test_size=0.33,
8 random state=42)
9 X, Y
    (array([[0, 1],
            [2, 3],
            [4, 5],
            [6, 7],
            [8, 9]), range(0, 5))
```

Primjer koristenja Pickle datoteke

3 Zadaci za rad u laboratoriji

Predviđeno je da se svi zadaci u nastavku rade u sklopu Jupyter Notebook okruženja. Svaki podzadatak treba biti zasebna Jupyter ćelija.

Zadatak 1 - Obrada podataka kroz Pandas

Uz vježbu ste dobili datoteku izvjestaj.csv. Potrebno je, koristeći Pandas:

a) Učitati datoteku kao Pandas DataFrame, te prikazati prvih 5 i posljednjih 10 unosa u istoj

```
1 #Priprema podataka za prvi zadatak
2 import numpy as np # ucitaj NumPy
3 import pandas as pd # ucitaj Pandas
4
5 data = pd.read_csv('dataset.csv') # ucitaj podatke
6
7 data.head() #prvih 5
8 data.tail(10) #zadnjih 10
```

b) Ispisati samo podatke vezane za redovne parcijalne ispite (kolone Ispit1 i Ispit2);

1 data.loc[:, ['Ispit1', 'Ispit2']]

c) Ispisati sve studente koji su izgubili prisustvo

1 data.loc[data['Prisustvo'] == 0]

c) Ispisati indeks, ukupne bodove, i ocjenu, za sve studente koji su upisali ocjenu 8 ili više;

1 data.loc[data['Ocjena'] >= '8', ['Indeks', 'UKUPNO', 'Ocjena']]

- e) Sve nedostajuće vrijednosti (označene sa simbolom /) zamijeniti sa vrijednošću np.nan
- 1 data.replace('/', np.nan, inplace=True)
- 2 data

- f) Iz skupa podataka odbaciti sve studente koji nemaju upisanu ocjenu
- 1 data.dropna(subset=['Ocjena'])

g) Kreirati novu kolonu Ispit1_final u koju ćete za svakog studenta upisati onaj rezultat ispita koji je bolji (na primjer, ako je student bolje uradio popravni ispit, onda tu pišete bodove sa popravnog, a u protivnom sa redovnog);

```
1 ispitiRedovni = data["Ispit1"]
2 ispitiPopravni = data["Ispit1_popravni"]
```

```
3 ispitiFinal = []
 4 for i in range(0,len(ispitiRedovni)):
    if(isinstance(ispitiRedovni[i],str) != True and isinstance(ispitiPopravni[i],str)!=True)
 6
      ispitiFinal.append(ispitiRedovni[i])
 7
    elif (isinstance(ispitiRedovni[i],str) != True ): #Ako nije izlazio na redovni, automats
 8
      ispitiFinal.append(ispitiPopravni[i])
 9
    elif (isinstance(ispitiPopravni[i],str) != True ): #Ako nije izlazio na popravni, automa
      ispitiFinal.append(ispitiRedovni[i])
10
    elif (float(ispitiRedovni[i])>=float(ispitiPopravni[i])): #Ako je vise imao na redovnom
11
12
       ispitiFinal.append(ispitiRedovni[i])
    else: #U ostalim slucajevima upisujemo popravni
13
      ispitiFinal.append(ispitiPopravni[i])
14
15
16 data['Ispit1 final']=ispitiFinal
17 data
18
```

- h) Ponoviti postupak za Ispit2
- 1 ispitiRedovni = data["Ispit2"]
- 2 ispitiPopravni = data["Ispit2_popravni"]

```
3 ispitiFinal = []
 4 for i in range(0,len(ispitiRedovni)):
    if(isinstance(ispitiRedovni[i],str) != True and isinstance(ispitiPopravni[i],str)!=True)
 6
      ispitiFinal.append(ispitiRedovni[i])
 7
    elif (isinstance(ispitiRedovni[i],str) != True ): #Ako nije izlazio na redovni, automats
 8
      ispitiFinal.append(ispitiPopravni[i])
 9
    elif (isinstance(ispitiPopravni[i],str) != True ): #Ako nije izlazio na popravni, automa
      ispitiFinal.append(ispitiRedovni[i])
10
    elif (float(ispitiRedovni[i])>=float(ispitiPopravni[i])): #Ako je vise imao na redovnom
11
12
       ispitiFinal.append(ispitiRedovni[i])
    else: #U ostalim slucajevima upisujemo popravni
13
      ispitiFinal.append(ispitiPopravni[i])
14
15
16 data['Ispit2 final']=ispitiFinal
17 data
```

i) Odbaciti četiri stare kolone za ispite

```
1 data.drop(columns=['Ispit1','Ispit2','Ispit1_popravni', 'Ispit2_popravni'], inplace=True)
2 data
```

j) Skup podataka sačuvati kao CSV datoteku pod nazivom izvjestaj_modificirano.csv. Koristiti znak tačka-zarez kao separator

```
1 data.to_csv('izvjestaj_modificirano.csv',index=False)
2
3
```

k) Skup podataka sačuvati kao Pickle datoteku pod nazivom izvjestaj_modificirano_pickle.p.

```
1 import pickle
2 pickle.dump(data, open( "izvjestaj_modificirano.p", "wb" ), protocol=pickle.HIGHEST_PROTOC
```

Zadatak 2 - Normalizacija podataka pomoću Sklearn

a) Učitati datoteku izvjestaj.csv kao Pandas DataFrame;

- 1 import pandas as pd
- 2 import numpy as np # ucitaj NumPy
- 3 data = pd.read_csv('dataset.csv') # ucitaj podatke
- 4 data.replace('/', np.nan, inplace=True)
- 5 data

b) Za kolone koje predstavljaju redovne ispite, izvršiti zamjenu nedostajućih vrijednosti strategijom median

```
1 from sklearn.impute import SimpleImputer
2 si = SimpleImputer(strategy='median')
3
4 print('Prije zamjene: ')
5 print(data.loc[:5, 'Ispit1'])
6 print(data.loc[:5, 'Ispit2'])
7 data.loc[:, 'Ispit1'] = si.fit_transform(data.loc[:, 'Ispit1'].values.reshape(-1,1))
8 data.loc[:, 'Ispit2'] = si.fit_transform(data.loc[:, 'Ispit2'].values.reshape(-1,1))
9 print('Nakon zamjene: ')
10 print(data.loc[:5, 'Ispit1'])
11 print(data.loc[:5, 'Ispit2'])
```

```
Prije zamjene:
      9.4
      8.5
1
2
       17
3
      7.6
     10.6
5
      NaN
Name: Ispit1, dtype: object
      7.5
1
      NaN
2
     NaN
3
      4.8
4
     12.5
      NaN
Name: Ispit2, dtype: object
Nakon zamjene:
      9.4
1
      8.5
2
     17.0
3
     7.6
4
     10.6
5
     12.5
Name: Ispit1, dtype: float64
      7.5
1
      8.7
2
      8.7
3
      4.8
     12.5
      8.7
Name: Ispit2, dtype: float64
```

c) Za kolone koje predstavljaju popravne ispite, izvršiti zamjenu nedostajućih vrijednosti pomoću strategije mean

```
1 from sklearn.impute import SimpleImputer
 2 si = SimpleImputer(strategy='mean')
4 print('Prije zamjene: ')
5 print(data.loc[:5, 'Ispit1 popravni'])
6 print(data.loc[:5, 'Ispit2 popravni'])
7 data.loc[:, 'Ispit1_popravni'] = si.fit_transform(data.loc[:, 'Ispit1_popravni'].values.re
8 data.loc[:, 'Ispit2 popravni'] = si.fit transform(data.loc[:, 'Ispit2 popravni'].values.re
9 print('Nakon zamjene: ')
10 print(data.loc[:5, 'Ispit1 popravni'])
11 print(data.loc[:5, 'Ispit2_popravni'])
    Prije zamjene:
         12.08
    1
            NaN
    2
            NaN
     3
            NaN
         12.58
```

```
5
     13.08
Name: Ispit1 popravni, dtype: object
     13.73
1
       NaN
2
       NaN
3
       NaN
       NaN
     12.83
Name: Ispit2 popravni, dtype: object
Nakon zamjene:
    12.080
     10.657
1
2
    10.657
3
    10.657
4
     12.580
    13.080
Name: Ispit1 popravni, dtype: float64
    13.730000
1
    14.662727
    14.662727
3
    14.662727
    14.662727
5
     12.830000
Name: Ispit2 popravni, dtype: float64
```

d) Izvršiti Z-score normalizaciju vrijednosti za redovne parcijalne ispite

```
1 from sklearn.preprocessing import scale
 2 print("Ispit 1 prije normalizacije")
 3 print(data.loc[:5,'Ispit1'])
4 data['Ispit1'] = scale(data['Ispit1'])
 5 print("Ispit 1 poslije normalizacije")
 6 print(data.loc[:5, 'Ispit1'])
7
8 print("Ispit 2 prije normalizacije")
9 print(data.loc[:5,'Ispit2'])
10 data['Ispit2'] = scale(data['Ispit2'])
11 print("Ispit 2 poslije normalizacije")
12 print(data.loc[:5, 'Ispit2'])
    Ispit 1 prije normalizacije
          9.4
    1
          8.5
    2
         17.0
     3
          7.6
    4
         10.6
         12.5
    Name: Ispit1, dtype: float64
    Ispit 1 poslije normalizacije
       -1.561766
    1
        -2.029964
    2
         2.391904
        -2.498161
```

```
4
    -0.937502
5
     0.050915
Name: Ispit1, dtype: float64
Ispit 2 prije normalizacije
      7.5
1
      8.7
2
      8.7
3
      4.8
4
    12.5
5
      8.7
Name: Ispit2, dtype: float64
Ispit 2 poslije normalizacije
    -0.555596
1
   -0.087900
2
   -0.087900
  -1.607912
4
    1.393136
5
  -0.087900
Name: Ispit2, dtype: float64
```

e) Izvršiti MinMax normalizaciju vrijednosti za popravne parcijalne ispite

```
1 from sklearn.preprocessing import MinMaxScaler
 2 mm = MinMaxScaler()
 3
4 print("Ispit1 popravni prije normalizacije")
 5 print(data.loc[:5,'Ispit1 popravni'])
6 data['Ispit1_popravni'] = mm.fit_transform(data['Ispit1_popravni'].values.reshape(-1,1))
7 print("Ispit1 popravni poslije normalizacije")
8 print(data.loc[:5, 'Ispit1 popravni'])
10 print("Ispit2 popravni prije normalizacije")
11 print(data.loc[:5,'Ispit2_popravni'])
12 data['Ispit2 popravni'] = mm.fit transform(data['Ispit2 popravni'].values.reshape(-1,1))
13 print("Ispit2 popravni poslije normalizacije")
14 print(data.loc[:5, 'Ispit2 popravni'])
    Ispit1 popravni prije normalizacije
         12.080
    1
         10.657
     2
         10.657
     3
         10.657
         12.580
         13.080
    Name: Ispit1 popravni, dtype: float64
    Ispit1 popravni poslije normalizacije
         0.795918
    1
         0.679755
     2
         0.679755
     3
         0.679755
    4
         0.836735
         0.877551
    Name: Ispit1 popravni, dtype: float64
```

```
Ispit2_popravni prije normalizacije
    13.730000
1
    14.662727
    14.662727
3
    14.662727
    14.662727
5
    12.830000
Name: Ispit2_popravni, dtype: float64
Ispit2 popravni poslije normalizacije
    0.401146
1
    0.490232
2
    0.490232
3
    0.490232
4 0.490232
5
    0.315186
Name: Ispit2_popravni, dtype: float64
```

f) Sve ostale nedostajuće vrijednosti u skupu podataka zamijeniti sa nulama

```
1 data.replace(np.nan, '0', inplace=True)
2 data
```

g) Izdvojiti kolonu Ocjena u posebnu varijablu, na način da sada u originalnom skupu podataka ta kolona više ne postoji

```
1 print("Prije izdvajanja kolone Ocjena: ")
2 print(data)
3 ocjene = data.pop("Ocjena")
4 print("Poslije izdvajanja kolone Ocjena: ")
5 print(data)
6 print("Ocjene: ")
7 print(ocjene)
```

```
Prije izdvajanja kolone Ocjena:
    id Indeks
              Prisustvo
                             Ispit1
                                        Ispit2
                                                Ispit1 popravni
        94-ST
                       10 -1.561766 -0.555596
                                                       0.795918
     1
1
     2
        77-ST
                       10 -2.029964 -0.087900
                                                       0.679755
2
     3
        69-ST
                          2.391904 -0.087900
                                                       0.679755
3
        79-ST
                        0 -2.498161 -1.607912
                                                       0.679755
4
     5
        89-ST
                       10 -0.937502
                                     1.393136
                                                       0.836735
5
                           0.050915 -0.087900
        78-ST
                                                       0.877551
6
     7
        93-ST
                       10
                           0.050915
                                     1.393136
                                                       0.844082
7
        68-ST
                           0.050915 -0.087900
                                                       0.679755
     8
                       10
8
     9
        83-ST
                           0.050915 -0.087900
                                                       0.679755
9
        92-ST
                       10
                           0.050915 -0.087900
                                                       0.679755
    10
10
   11
        65-ST
                           0.050915 -0.087900
                                                       0.679755
                       10
11
   12
        70-ST
                       10
                          0.311025 -0.438672
                                                       0.679755
12
   13
        90-ST
                       10
                           1.663596 -0.477647
                                                       0.679755
13
   14
        97-ST
                       10
                          0.050915 -0.087900
                                                       0.679755
14
   15
        84-ST
                       10
                          0.050915 -0.087900
                                                       0.679755
15
   16
        98-ST
                       10
                           0.050915 -0.438672
                                                       0.679755
   17
        91-ST
                           0.050915 -0.087900
                                                       0.679755
16
                       10
17
   18
        87-ST
                       10
                           0.050915 -0.087900
                                                       0.679755
18
   19
        76-ST
                       10
                           0.050915 -0.087900
                                                       0.679755
19
    20
        96-ST
                       10
                           0.050915 -0.087900
                                                       0.679755
20
   21
        66-ST
                       10
                           0.831245 0.301846
                                                       0.679755
21
    22
        62-ST
                           0.050915 -0.087900
                                                       0.679755
                       10
22
   23
        74-ST
                       0 -0.885480 -0.087900
                                                       1.000000
23
    24
        86-ST
                       10
                           0.623157
                                     1.393136
                                                       0.679755
24
    25
        73-ST
                           0.050915 -0.945343
                       10
                                                       0.679755
25
   26
                           0.050915 -0.087900
        80-ST
                       10
                                                       0.679755
26
   27
        63-ST
                       10
                           2.183816 -0.087900
                                                       0.679755
27
    28
        72-ST
                           0.050915 -0.087900
                                                       0.679755
                       10
28
    29
        95-ST
                        0 -0.833458
                                     1.393136
                                                       0.401633
29
   30
        85-ST
                       10
                           0.050915
                                     1.393136
                                                       0.679755
30
   31
        99-ST
                       10
                           0.050915 -0.087900
                                                       0.966531
31
   32
        41-ST
                           0.050915 -0.087900
                                                       0.679755
32
    33
        17-ST
                        0 -2.550183 -2.816126
                                                       0.000000
33
    34
        82-ST
                         -1.249634 -2.894075
                                                       0.679755
34
   35
        15-ST
                           0.050915 -0.087900
                                                       0.679755
                                     2.367503
                                                       0.679755
35
   36
        64-ST
                       10
                           0.467091
36
   37
        44-ST
                       10
                           0.050915 -0.087900
                                                       0.462857
                           0.050915 -0.087900
37
    38
       71-ST
                       10
                                                       0.679755
   39
38
        54-ST
                       10
                           0.050915 -0.087900
                                                       0.679755
39
   40
        60-ST
                       10 -1.249634 -0.087900
                                                       0.679755
40
       48-ST
                       10 0.050915 -0.087900
                                                       0.679755
   41
```

```
41 42 61-ST
                    10 0.050915 -0.087900
                                                  0.679755
42 43
       1-ST
                    10 0.050915 -0.087900
                                                  0.679755
43 44 88-ST
                    10 0.050915 -0.087900
                                                  0.679755
44 45 75-ST
                    10 0.050915 -0.087900
                                                  0.612245
45 46 67-ST
                    10 2.131794 -0.087900
                                                  0.679755
46 47 81-ST
                    10 1.715618 3.263919
                                                  0.679755
   Ispit2 popravni UKUPNO Ocjena
          0.401146 35.81
          0.490232 35.50
1
2
          0.490232 39.50
3
          0.490232 12.40
                               0
4
          0.490232 35.08
                   25.91
5
          0.315186
                               6
          a 100727
                    25 17
```

h) Konvertovati obje varijable (originalni skup podataka bez kolone Ocjena, kao i posebnu kolonu Ocjena) u NumPy nizove

```
1 print("Prije konvertovanja: ")
2 print(data)
3 print(ocjene)
4 print("Poslije konvertovanja: ")
5 data = data.to_numpy()
6 ocjene = ocjene.to_numpy()
7 print(data)
8 print(ocjene)
     0.6797551020408164 0.4902318312060433 42.06]
     [11 '65-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 43.19]
     [12 '70-ST' 10 0.3110249685383584 -0.4386721044704893 0.6797551020408164
     0.646609360076409 39.31
     [13 '90-ST' 10 1.663596184032576 -0.47764675269376516 0.6797551020408164
     0.45558739255014336 39.9]
     [14 '97-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 41.05]
     [15 '84-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 43.56]
     [16 '98-ST' 10 0.050915119404855075 -0.4386721044704893
     0.6797551020408164 0.0 38.5]
     [17 '91-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 43.48]
     [18 '87-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 35.89]
     [19 '76-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 27.18]
     [20 '96-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 41.4]
     [21 '66-ST' 10 0.8312446668053652 0.30184621177175464 0.6797551020408164
     0.617956064947469 40.0]
     [22 '62-ST' 10 0.050915119404855075 -0.08790027046100546
     0.6797551020408164 0.4902318312060433 42.0]
     [23 '74-ST' 0 -0.8854803374757575 -0.08790027046100546
     0.99999999999999 0.20725883476599816 27.081
```

```
[24 '86-ST' 10 0.6231567874985623 1.3931363620234831 0.6797551020408164
 0.4902318312060433 36.1]
[25 '73-ST' 10 0.050915119404855075 -0.9453425313730773
 0.6797551020408164 0.9111747851002866 41.57]
[26 '80-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 39.45]
[27 '63-ST' 10 2.1838158822995837 -0.08790027046100546
 0.6797551020408164 1.0 46.6]
[28 '72-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 18.41]
[29 '95-ST' 0 -0.833458367649056 1.3931363620234831 0.40163265306122453
0.4902318312060433 23.5]
[30 '85-ST' 10 0.050915119404855075 1.3931363620234831
 0.6797551020408164 0.4902318312060433 35.25]
[31 '99-ST' 10 0.050915119404855075 -0.08790027046100546
 0.9665306122448979 0.4902318312060433 24.17]
[32 '41-ST' 0 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 5.87]
[33 '17-ST' 0 -2.5501833719301787 -2.8161256460903257 0.0
 0.4902318312060433 9.2]
[34 '82-ST' 0 -1.2496341262626618 -2.8940749425368777 0.6797551020408164
 0.4902318312060433 16.0]
[35 '15-ST' 0 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 0.0]
[36 '64-ST' 10 0.46709087801846083 2.367502567605383 0.6797551020408164
0.4902318312060433 38.31
[37 '44-ST' 10 0.050915119404855075 -0.08790027046100546
 0.46285714285714286 0.45845272206303733 32.33]
[38 '71-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 42.16]
[39 '54-ST' 10 0.050915119404855075 -0.08790027046100546
```

i) Ukoliko pretpostavimo da NumPy niz sa ocjenama predstavlja labele, a niz sa ostalim kolonama atribute (značajke), izvršiti podjelu na trening i testni skup podataka, pri čemu za testni skup treba uzeti 20% podataka.

```
[2 '77-ST' 10 -2.029963673663172 -0.08790027046100546 0.6797551020408164
 0.4902318312060433 35.5]
 [42 '61-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 23.12]
 [22 '62-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 42.0]
 [3 '69-ST' 10 2.3919037616063856 -0.08790027046100546 0.6797551020408164
 0.4902318312060433 39.5]
[36 '64-ST' 10 0.46709087801846083 2.367502567605383 0.6797551020408164
 0.4902318312060433 38.3]
 [24 '86-ST' 10 0.6231567874985623 1.3931363620234831 0.6797551020408164
 0.4902318312060433 36.1]
[38 '71-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 42.16]
 [11 '65-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 43.19]
 [23 '74-ST' 0 -0.8854803374757575 -0.08790027046100546
 0.99999999999999 0.20725883476599816 27.08]
 [19 '76-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 27.18]
[47 '81-ST' 10 1.7156181538592763 3.263919476740732 0.6797551020408164
 0.4902318312060433 43.0]
 [21 '66-ST' 10 0.8312446668053652 0.30184621177175464 0.6797551020408164
 0.617956064947469 40.0]
[8 '68-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 50.0]
 [43 '1-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 10.0]
[15 '84-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 43.56]
 [29 '95-ST' 0 -0.833458367649056 1.3931363620234831 0.40163265306122453
 0.4902318312060433 23.5]
 [39 '54-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 19.35]]
Data test:
[[28 '72-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 18.41]
 [40 '60-ST' 10 -1.2496341262626618 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 38.5]
 [27 '63-ST' 10 2.1838158822995837 -0.08790027046100546
 0.6797551020408164 1.0 46.6]
 [44 '88-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 37.0]
 [25 '73-ST' 10 0.050915119404855075 -0.9453425313730773
 0.6797551020408164 0.9111747851002866 41.57]
 [37 '44-ST' 10 0.050915119404855075 -0.08790027046100546
 0.46285714285714286 0.45845272206303733 32.33]
 [13 '90-ST' 10 1.663596184032576 -0.47764675269376516 0.6797551020408164
 0.45558739255014336 39.91
 [20 '96-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 41.4]
 [5 '89-ST' 10 -0.937502307302458 1.3931363620234831 0.836734693877551
 0.4902318312060433 35.08]
 [26 '80-ST' 10 0.050915119404855075 -0.08790027046100546
 0.6797551020408164 0.4902318312060433 39.45]]
Ociene train:
```

Zadatak 3 - Klasični algoritam mašinskog učenja

U ovom zadatku, upoznat ćemo se sa primjenom Sklearn biblioteke u klasičnim algoritimma mašinskog učenja. Konkretno, radit će se klasifikacija cvijeta iris na tri različite vrste (prikazane na slici u postavci), i to: • Setosa; • Versicolour; • Virginica;

Algoritam će prvo na osnovu postojećeg skupa podataka, koji sadrži značajke i labele, naučiti kako koja značajka djeluje samu vrstu cvijeta, te će biti u stanju da za novi (neviđeni) podatak pretpostavi tačnu klasu kojoj cvijet pripada.

a) Sam skup podataka dolazi spreman uz Sklearn, te ga je potrebno učitati:

```
1 from sklearn.datasets import load iris
 3 iris = load iris()
4 X = iris.data
5 y = iris.target
7 feature_names = iris.feature_names
8 target names = iris.target names
10 print("Nazivi znacajki:", feature_names)
11 print("Nazivi labela:", target names)
12 print("\nPrvih 5 redova X:\n", X[:5])
    Nazivi znacajki: ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal
    Nazivi labela: ['setosa' 'versicolor' 'virginica']
    Prvih 5 redova X:
     [[5.1 3.5 1.4 0.2]
     [4.9 3. 1.4 0.2]
     [4.7 3.2 1.3 0.2]
     [4.6 3.1 1.5 0.2]
     [5. 3.6 1.4 0.2]]
```

b) Sljedeći korak jeste dijeljenje skupa podataka na dva dijela - trening i testni skup. Trening skup se koristi kako bi algoritam naučio uzorke ponašanja, dok testni skup predstavlja nove podatke, na osnovu kojih se vrši evaluacija algoritma (to jeste evaluacija naučenog).

```
1 from sklearn.model_selection import train_test_split
2
3 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state =
```