Pokretanje primjera iz uvodnog dijela laboratorijske vježbe

Na prvoj laboratorijskoj vježbi iz neuronskih mreža, studenti se upoznaju sa problemom klasifikacije, kao jednim od najčešćih problema iz prakse. Kroz zadatke, studenti rješavaju jednostavne probleme klasifikacije nad tekstualnim ulaznim podacima, koristeći Keras razvojni okvir.

Prikazivanje osnovnih informacija o skupu podataka poput minimalne vrijednosti, maksimalne vrijednosti, srednje vrijednosti, standardne devijacije, i tako dalje.

```
1 import pandas as pd
2 data = pd.read_csv('dataset.csv')
3 data.describe()
```

Pandas modul omogućava i crtanje histograma za svaki od atributa:

```
1 import pandas as pd
2 data = pd.read_csv('dataset.csv')
3 data.hist()
4
```

Primjer vršenja normalizacije

```
1 import numpy as np
 2 from sklearn.preprocessing import MinMaxScaler
 3 from sklearn.model_selection import train_test_split
 5 #pripremanje testnih podataka
 6 X, Y = np.arange(10).reshape((5, 2)), range(5)
 7 x_train, x_test, y_train, y_test = train_test_split(X, Y, test_size=0.33, random_state=42)
 8
 9 #Normalizacija
10 scaler = MinMaxScaler().fit(x train)
11 x train = scaler.fit transform(x train)
12 x test = scaler.fit transform(x test)
13
14 x train, x test
    (array([[0.66666667], 0.66666667],
            [0. , 0. ],
            [1. , 1.
                                  ]]), array([[0., 0.],
            [1., 1.]))
```

Primjer vršenja standardizacije

```
1 import numpy as np
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.model_selection import train_test_split
4
5 #pripremanje testnih podataka
6 X, Y = np.arange(10).reshape((5, 2)), range(5)
7 x_train, x_test, y_train, y_test = train_test_split(X, Y, test_size=0.33, random_state=42)
8
9 #Standardizacija
10 scaler = StandardScaler().fit(x_train)
11 x_train = scaler.transform(x_train)
12 x_test = scaler.transform(x_test)
```

Primjer za model koji bi mogao poslužiti za binarnu klasifikaciju:

Postavljanje funckije gubitka, optimizatora kao i metrike koja će se pratiti na modelu

```
1 #Adam optimizator sa podrazumijevanim postavkama
2 model.compile(optimizer='adam',loss='binary_crossentropy',metrics=['accuracy'])
3
4 #eksplicitno podesavanje istog optimizatora
5 '''from tensorflow import keras
6 opt = keras.optimizers.Adam(learning_rate=0.01)
7 model.compile(loss='categorical_crossentropy', optimizer=opt, metrics=['accuracy'])'''
8
```

Zadatak 1 - Binarna klasifikacija - Klasifikacija vina

a) Učitati podatke za crno i bijelo vino koji se nalaze u CSV datotekama winequality-red.csv i winequality-white.csv u varijable red i white respektivno. Pri ovome postaviti parametar separator da bude znak tačka-zarez (;). U odgovarajućim DataFrame objektima dodati novu kolonu label koja će imati vrijednost 0 za podatke bijelog vina, a vrijednost 1 za podatke crnog vina. Nakon ovoga spojiti ih u jedan DataFrame objekat wines.

```
1 import pandas as pd
2 import numpy as np
3
4 #ucitavanje podataka, kao i postavljanje separatora
5 red = pd.read_csv("winequality-red.csv",sep=";")
6 white = pd.read_csv("winequality-white.csv",sep=";")
7
8 #dodavanje kolone "label", gdje je crvenom vinu label = 1, a bijelom = 0
9 red["label"] = 1
10 white["label"] = 0
11
12 #spajanje u jedan DataFrame objekat
13 wines = pd.concat([white,red],ignore_index=True)
14 wines
15
16
```

b) Izvršiti prikaz osnovnih podataka spojenog skupa podataka korištenjem **describe** metode te nacrtati histograme korištenjem **hist** metode. Šta možete zaključiti o podacima?

```
1 wines.describe()
2
```

1 wines.hist(figsize=(15,20))

c) Iz wines izdvojiti X - karakteristike i y - labele. Zatim korištenjem funkcije train_test_split podijeliti podatke na one za treniranje i one za testiranje pri čemu 20% podataka trebaju biti podaci za testiranje;

```
1 #izdvoji/pripremi/razvrstaj podatke za train i test split
2 x = wines.drop("label",axis=1)
3 y = wines["label"]
4
```

```
5 #razdvajanje podataka na skupove za treniranje i za testiranje
6 x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
7
```

d) Formirati sekvencijalni Keras model koji će imati 2 Dense sloja sa po 8 neurona i relu aktivacijskom funkcijom. Prvom sloju kao input_shape parametar proslijediti vrijednost (12,) s obzirom na to da skup podataka ima 12 značajki. Treći sloj, koji je u ovom slučaju izlazni sloj, postaviti da također bude Dense, ali sa samo jednim neuronom;

```
1 from keras import models
2 from keras import layers
3 model = models.Sequential()
4 model.add(layers.Dense(8, activation = "relu", input_shape=(12,)))
5 model.add(layers.Dense(8, activation = "relu"))
6 model.add(layers.Dense(1, activation = "sigmoid"))
7
```

e) Kompajlirati model tako da koristi adam optimizator, za funkciju gubitka koristiti binary_crossentropy, a kao metriku odabrati accuracy;

```
1 model.compile(optimizer='adam',loss='binary_crossentropy',metrics=['accuracy'])
2
```

f) Model istrenirati na 20 epoha, sa veličinom batch-a 16.

```
1 history = model.fit(x_train, y_train, epochs=20, batch_size=16, validation_split=0.2)
```

```
Epoch 1/20
260/260 [============= ] - 1s 3ms/step - loss: 0.4484 - accuracy: 0.8126
Epoch 2/20
Epoch 3/20
260/260 [============= ] - 1s 2ms/step - loss: 0.1898 - accuracy: 0.9389
Epoch 4/20
260/260 [============= ] - 1s 2ms/step - loss: 0.1832 - accuracy: 0.9408
Epoch 5/20
Epoch 6/20
Epoch 7/20
Epoch 8/20
260/260 [================ ] - 1s 2ms/step - loss: 0.1597 - accuracy: 0.9476
Epoch 9/20
260/260 [================ ] - 1s 2ms/step - loss: 0.1540 - accuracy: 0.947
```

```
Epoch 10/20
Epoch 11/20
Epoch 12/20
260/260 [============= ] - 1s 2ms/step - loss: 0.1144 - accuracy: 0.9598
Epoch 13/20
Epoch 14/20
260/260 [============= ] - 1s 2ms/step - loss: 0.0962 - accuracy: 0.9666
Epoch 15/20
Epoch 16/20
260/260 [=============== ] - 1s 2ms/step - loss: 0.0870 - accuracy: 0.9721
Epoch 17/20
260/260 [============ ] - 1s 2ms/step - loss: 0.0823 - accuracy: 0.9735
Epoch 18/20
Epoch 19/20
Epoch 20/20
260/260 [============== ] - 1s 2ms/step - loss: 0.0767 - accuracy: 0.9759
```


```
1 from matplotlib import pyplot as plt
2 acc = history.history['accuracy']
3 loss_values = history.history['loss']
4 val_loss_values = history.history['val_loss']
5 epochs = range(1, len(acc) + 1)
6 plt.plot(epochs, loss_values, 'bo', label='Training loss')
7 plt.plot(epochs, val_loss_values, 'b', label='Validation loss')
8 plt.title('Training and validation loss')
9 plt.xlabel('Epochs')
10 plt.ylabel('Loss')
11 plt.legend()
```

g) Ponoviti postupak, no ovaj put prije treniranja izvršiti standardizaciju, odnosno skaliranje atributa korištenjem StandardScaler objekat iz sklearn.preprocessing modula. Kolika je sada tačnost nakon treniranja? Uporediti rezultate sa onim bez skaliranja

```
1 red = pd.read csv("winequality-red.csv",sep=";")
2 white = pd.read_csv("winequality-white.csv",sep=";")
3 X = wines.drop("label",axis=1)
4 y = wines["label"]
5 X_train, X_test, y_train, y_test = train_test_split(
6 X, y, test size=0.2, random state=42)
7 from sklearn.preprocessing import StandardScaler
8 scaler = StandardScaler().fit(X train)
9 X train = scaler.transform(X train)
10 X test = scaler.transform(X test)
11 model.compile(optimizer='adam',loss='binary crossentropy',metrics=['accuracy'])
12 history = model.fit(X_train, y_train, epochs=20, batch_size=16, validation_split=0.2)
13
   Epoch 1/20
   260/260 [============= ] - 1s 3ms/step - loss: 0.3049 - accuracy: 0.9296
   Epoch 2/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0904 - accuracy: 0.975!
   Epoch 3/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0613 - accuracy: 0.9827
   Epoch 4/20
   260/260 [============ ] - 1s 3ms/step - loss: 0.0496 - accuracy: 0.9868
   Epoch 5/20
   Epoch 6/20
   Epoch 7/20
   260/260 [============ ] - 1s 3ms/step - loss: 0.0351 - accuracy: 0.992
   Epoch 8/20
   260/260 [============== ] - 1s 2ms/step - loss: 0.0327 - accuracy: 0.993!
   Epoch 9/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0312 - accuracy: 0.993
   Epoch 10/20
   260/260 [============ ] - 1s 2ms/step - loss: 0.0299 - accuracy: 0.993
   Epoch 11/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0290 - accuracy: 0.9947
   Epoch 12/20
   Epoch 13/20
   Epoch 14/20
   260/260 [============ ] - 1s 2ms/step - loss: 0.0262 - accuracy: 0.9959
   Epoch 15/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0257 - accuracy: 0.9952
   Epoch 16/20
   260/260 [============= ] - 1s 2ms/step - loss: 0.0252 - accuracy: 0.9954
   Epoch 17/20
```

```
1 from matplotlib import pyplot as plt
2 acc = history.history['accuracy']
3 loss_values = history.history['loss']
4 val_loss_values = history.history['val_loss']
5 epochs = range(1, len(acc) + 1)
6 plt.plot(epochs, loss_values, 'bo', label='Training loss')
7 plt.plot(epochs, val_loss_values, 'b', label='Validation loss')
8 plt.title('Training and validation loss')
9 plt.xlabel('Epochs')
10 plt.ylabel('Loss')
11 plt.legend()
```

<matplotlib.legend.Legend at 0x7f30524466d0>



h) Model evaluirati nad testnim skupom podataka. Kolika je postignuta tačnost modela?